

# Отчёт по сессионному проекту по дисциплине

«Fundamentals of Data Mining and Machine Learning»

## Авторы:

Тұрғын Салтанат

Уршукова Томирис

## 1. Цель проекта

Целью данного проекта является практическое освоение базовых алгоритмов машинного обучения, а именно:

- линейной регрессии,
- логистической регрессии,
- методов классификации,

путём **реализации алгоритмов с нуля** и их сравнения с готовыми моделями библиотеки `scikit-learn`.

Дополнительной целью является анализ влияния гиперпараметров (learning rate, epochs, batch size) на процесс обучения моделей.

## 2. Описание датасета

В проекте использован открытый датасет **IMDb Video Games Dataset**, полученный с платформы Kaggle.

**Источник:** Kaggle

**Ссылка:** <https://www.kaggle.com/datasets/lorentzyeung/imdb-video-games-dataset>

**Размер датасета:** 14 682 наблюдения

Датасет содержит информацию о видеоиграх, включая оценки пользователей и показатели популярности.

### Основные используемые признаки:

- **User Rating** — числовая оценка пользователей
- **Popularity** — показатель популярности игры (целевая переменная)

Датасет является реальным, структурированным и удовлетворяет всем требованиям проекта.

### Влияние скорости обучения на сходимость

График “Влияние скорости обучения на сходимость при градиентном спуске” показывает, что:

$lr = 0,01$  продемонстрировал наилучшую сходимость к минимальному MSE.

Более высокие значения  $lr$  (например, 0,05, 0,1, 0,3) приводили к расхождению (значительному росту MSE) или нестабильному поведению, что подтверждалось такими ошибками, как

RuntimeWarning: переполнение встречается в квадратных и

RuntimeWarning: недопустимое значение, обнаруженное при вычитании.

## 3. Линейная регрессия

### 3.1 Модель

Используется одномерная линейная регрессия:

$$\hat{y} = wx + b$$

### 3.2 Функция потерь

В качестве функции потерь используется среднеквадратичная ошибка (MSE):

$$L = \frac{1}{n} \sum_{i=1}^n (y_i - (wx_i + b))^2$$

### 3.3 Градиенты

$$\frac{\partial L}{\partial w} = -\frac{2}{n} \sum_{i=1}^n x_i (y_i - \hat{y}_i)$$

$$\frac{\partial L}{\partial b} = -\frac{2}{n} \sum_{i=1}^n (y_i - \hat{y}_i)$$

Обучение производится с помощью **batch gradient descent**, реализованного вручную с использованием numpy.

## 4. Логистическая регрессия

### 4.1 Формулировка задачи

Задача бинарной классификации:

- 0 — низкая популярность (ниже медианы)
- 1 — высокая популярность (выше медианы)

### 4.2 Сигмоида

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

### 4.3 Функция потерь (Log-loss)

$$L = -\frac{1}{n} \sum_{i=1}^n [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]$$

## 4.4 Градиенты

$$\frac{\partial L}{\partial w} = \frac{1}{n} X^T (\hat{y} - y)$$

$$\frac{\partial L}{\partial b} = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)$$

Обучение выполняется с использованием **mini-batch gradient descent** и L2-регуляризации.

## 5. Классификация и сравнение моделей

В проекте сравниваются две модели:

- логистическая регрессия (реализация с нуля),
- Decision Tree (библиотека `scikit-learn`).

### Используемые метрики:

- Accuracy
- Precision
- Recall
- F1-score
- Confusion Matrix
- ROC AUC

### 5.1 Сравнение моделей

Модель	Accuracy	Precision	Recall	F1-score	ROC AUC
Логистическая регрессия (наша)	0.78	0.76	0.80	0.78	0.85
Decision Tree (sklearn)	0.82	0.81	0.83	0.82	0.88

## 6. Эксперименты

Проведены эксперименты с:

- различными значениями **learning rate**,
- количеством **epochs**,
- размером **batch size**.

Эксперименты показали, что:

- слишком большой learning rate приводит к нестабильной сходимости,
- увеличение количества эпох улучшает качество до определённого предела,
- mini-batch gradient descent обеспечивает более стабильное обучение.

### 6.1 Испытанные гиперпараметры

- **Learning rate:** 0.01, 0.05, 0.1, 0.3
- **Batch size:** 32, 64, 128
- **Epochs:** 100, 500, 1000
- **L2-регуляризация ( $\lambda$ ):** 0.01

## 7. Выводы

В ходе проекта были реализованы и исследованы базовые алгоритмы машинного обучения.

Логистическая регрессия показала стабильные результаты на бинарной классификации, а Decision Tree продемонстрировало способность моделировать нелинейные зависимости.

Проект подтвердил важность корректного выбора гиперпараметров и понимания внутренних механизмов алгоритмов машинного обучения.

